

Predicting Used Volkswagen Car Prices with Machine Learning in R



Svetlana Oshcepkova

EC Utbildning

R programming project

April 2025

Abstract

In this project, I built a model to predict the prices of used Volkswagen cars based on data collected from the Blocket marketplace. The work started with cleaning the data: I removed unnecessary columns like listing titles and registration numbers, fixed typos, and handled missing values. Categorical variables like fuel type, gearbox, and body type were organized using simple encoding, and the numbers were scaled to make the model training smoother.

The project followed a clear pipeline: preparing the data, building the model, improving it by selecting the most important features, and analysing the results. Each step was done carefully to make sure the model would perform well.

The final model showed good prediction results, confirmed by checking residuals and making sure there were no major issues with multicollinearity.

Table of Contents

Abstract	2
1 Inledning.....	1
2 Teori.....	3
2.1 Teoretisk modell för multipel regression i maskininlärning	3
2.2.....	3
Hypotestestning inom multipel regression	3
2.3 Regressionsmodellering: Potentiella problem	3
3 Metod	4
3.1 Data cleaning	4
3.1.1 Import av data	4
3.1.2 Rensning av numeriska variabler	4
3.2 Data Analysis.....	5
3.2.1 Modell år (model_year) kolumn analys.....	5
3.2.2 Fördelning av Bränsltyper (fuel) kolumn.....	6
3.2.3 Fördelning av biltyper	7
3.2.4 Fördelning av billmodeller (model) kolumn.....	8
3.3 Model val	9
3.3.1 Model 1.....	9
3.3.2 Full model testing	14
3.3.3 Function Regsubsets()	15
4 Resultat.....	17
5 Slutsatser	18
6 Självtvärdering.....	19
6.1 Utmaningar du haft under arbetet samt hur du hanterat dem.	19
6.2 Vilket betyg du anser att du skall ha och varför.	19
Källförteckning.....	20

1 Inledning

Målet med det här projektet är att skapa en maskininlärningsmodell som, baserat på Blocket-annonser för Volkswagen-bilar, kan prediktera priset på begagnade fordon. Modellen använder bilens ålder, hästkrafter, körsträcka, bränsletyp och växellåda som prediktorer för att ge en uppskattning av ett rimligt marknadspris.

Det finns ett tydligt behov av en sådan modell. Statistiska centralbyråns (SCB) data visar att **antalet personbilar i trafik i Sverige har börjat minska något under de senaste två åren (Se Bild 1)**, efter att ha ökat stadigt i över ett decennium. Samtidigt visar SCB:s inkomststatistik att **genomsnittsinkomsterna fortsätter öka (Se Bild 2)** i ungefär samma takt som tidigare år.

Denna utveckling tyder på att många hushåll, trots ökade inkomster, väljer att inte köpa nya bilar, vilket sannolikt beror på den ekonomiska osäkerheten och den ökande inflationen. Det gör marknaden för begagnade bilar mer relevant än någonsin – både för köpare och säljare. Ett verktyg som med hjälp av maskininläring kan ge prisprognoser för begagnade bilar blir därmed praktiskt användbart i dagens läge.

Volkswagen har valts som fokuserat i detta projekt eftersom det är ett av de mest förekommande bilmärkena på den svenska begagnatmarknaden. Detta ger ett brett och representativt datamaterial som lämpar sig väl för modellträning och analys.



Bild 1. Data för Antal personbilar i Sverige 2002-2024 hämtat på CSB genom API




Bild 2: Data för Genomsnittlig Inkomst Sverige 2002-2024 för personer 20+ år, hämtat på CSB genom API

2 Teori

2.1 Teoretisk modell för multipel regression i maskininlärning

I detta projekt används en multipel linjär regressionsmodell för att förutsäga priset på begagnade bilar baserat på flera oberoende variabler, såsom körsträcka, hästkrafter, ålder, bränsletyp, växellåda och drivtyp. Den underliggande matematiska modellen kan uttryckas enligt följande:

$$\text{pris} = \beta_0 + \beta_1 \cdot \text{mile} + \beta_2 \cdot \text{horsepower} + \beta_3 \cdot \text{car_age} + \beta_4 \cdot \text{fuel_diesel} + \beta_5 \cdot \text{gearbox_manuell} + \beta_6 \cdot \text{drive_tvahjulsdriven} + \epsilon$$

Här representerar β_0 modellens intercept, medan $\beta_1 \dots \beta_6$ är koefficienter som anger varje variabels inverkan på bilens pris. Feltermen ϵ fångar upp variationer som modellen inte förklarar.

Denna modell gör det möjligt att kvantitativt analysera hur olika faktorer påverkar marknadspriset, och utgör därmed ett stabilt och tolkbart ramverk inom maskininlärningsbaserad prisprognos.

2.2

Hypotestestning inom multipel regression

Inom ramen för multipel linjär regression testas om de oberoende variablerna har en faktisk inverkan på den beroende variabeln, i detta fall bilens pris. För detta syfte formuleras en nollhypotes (H_0) som utgår från att det inte finns något statistiskt samband mellan de förklarande variablerna och priset:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

Det innebär att varken körsträcka, hästkrafter, bilens ålder, bränsletyp, växellåda eller drivtyp har någon signifikant effekt på bilens pris. Den alternativa hypotesen (H_1) lyder:

$$H_1: \text{Minst ett } \beta_i \neq 0$$

Det vill säga, minst en av variablerna påverkar priset signifikant. Hypotesprövningen sker dels genom analys av enskilda koefficienters p-värden, dels genom modellens övergripande F-test. Om p-värdena är låga (vanligtvis $< 0,05$) finns det stöd för att förkasta H_0 och därmed dra slutsatsen att de oberoende variablerna har förklaringsvärde.

I detta projekt har regressionsmodellen visat att samtliga valda variabler har statistiskt signifikanta effekter på priset, vilket ger starka skäl att förkasta nollhypotesen till förmån för H_1 .

2.3 Regressionsmodellering: Potentiella problem

Följande problem behöver hanteras under utveckling och förbättring av regressionsmodellen:

1. Icke-linjärt förhållande mellan den beroende variabeln och de oberoende variablerna.
2. Korrelerade residualer-Ej oberoende residualer
3. Icke .konstant varians på residualerna(Heteroskedasitet).
4. Ej normalfördelade residualer
5. Outliers
6. High Leverage punkter
7. Kollinearitet/Multikollinearitet

3 Metod

3.1 Data cleaning

I detta projekt genomfördes en omfattande datastädning för att säkerställa datakvalitet och skapa en stabil grund för vidare analys och modellering. Följande steg utfördes:

3.1.1 Import av data

Datafiler lästes in med korrekt teckenkodning (UTF-8) för att hantera svenska tecken korrekt. Onödiga kolumner (såsom "Unnamed" variabler) togs bort och endast relevanta variabler behölls.

3.1.2 Rensning av numeriska variabler

Numeriska variabler (price, mile, horsepower, model_year) rensades från icke-numeriska tecken (såsom mellanslag och kommatecken) och konverterades till numeriskt format.

Efter att ha visualiserat prisdatan som en boxplot ser jag två tydliga outliers. Eftersom syftet är att undersöka priserna för vanliga bilar, tar jag bort dessa rader.




Bild 3: Bil priser spridning

Efter det har bilpriser följande fördelning:(se Bild 4)




Bild 4: Bil priser fördelning

1. Hantering av kategoriska variabler

Samtliga kategoriska variabler (seller, fuel, gearbox, car_type, drive, model) omvandlades till små bokstäver för enhetlighet. Saknade värden och tomma strängar filtrerades bort. Vanliga stavfel i kategorier korrigerades, exempelvis:

- "disel" ändrades till "diesel"
- "miljöbränsle" ändrades till "miljöbränsle/hybrid"
- "halvkomni" ändrades till "halvkombi"

3.2 Data Analysis

3.2.1 Modell år (model_year) kolumn analys

Jag bestämde mig för att använda kolumnen model_year som grund för att räkna ut bilens ålder. Jag analyserade vilken kolumn som var mest relevant för att beräkna bilens ålder och kom fram till att, trots att skillnaden mellan värdena i model_year och date_in_traffic är statistiskt signifikant, ger modeller som använder model_year som grund för åldersberäkningen samma prestanda (baserat på *Adjusted R²*) som modeller där bilens ålder beräknas med hjälp av date_in_traffic. Eftersom date_in_traffic ofta innehåller många saknade värden, och information om bilens modellår är mer tillgänglig, valde jag att gå vidare med kolumnen model_year för att beräkna bilens ålder.

När jag analyserade datan i kolumnen visade det sig att för åren 2000 till 2009 består varje årsgrupp av mindre än 2 % av observationerna (Se Bild 4). Om en kategori (till exempel en årsmodellgrupp) innehåller mindre än 1–3 % av hela datamängden, betraktas den ofta som statistiskt svag vid träning av prediktiva modeller. Därför bestämde jag mig för att ta bort rader med dessa observationer, samt en observation från år 2025 som var den enda från det året.




Bild 5. Spridning av data i model_year kolumn

Vi behöver undersöka fördelningar av de kategoriska variabler för att bestämma vilken data och vilka variabler ska vi behålla för att bygga modellen.

3.2.2 Fördelning av Bränslrtyper (fuel) kolumn

Jag har valt att behålla alla bränsletyper eftersom storleken på varje bränslegrupp är större än 3% (Se Bild 6)




Bild 6: Antal bilar per Bränsletyp

3.2.3 Fördelning av biltyper

När jag analyserade data i kolumnen `car_type` visade det sig att vissa biltyper som Sedan, Coupe och Cab förekommer mycket sällan i datamängden — i vissa fall färre än 20 gånger per gruppen (se Bild 7). Eftersom datamängden totalt består av över 1076 observationer, motsvarar detta mindre än 2 % per biltyp. Jag bestämde att som i fall med vissa `model_year` det ska vara lönsamt att ta bort de observationerna eftersom de är statistiskt svaga vid träning av prediktiva modeller och ger tillräckligt med information för modellen att lära sig mönster på ett tillförlitligt sätt.

Vid senare testning av modellen visade det sig att modellens prestanda försämrades när vissa observationer togs bort. Därför har alla biltyper behållits i den slutliga regressionsmodellen.




Bild 7. Fordelning i car_type kolumn

3.2.4 Fördelning av bilmodeller (model) kolumn

Filtrering av ovanliga bilmodeller

Bilmodeller som förekom färre än tio gånger i datamängden identifierades och exkluderades för att minska varians och förbättra modellens generaliseringsförmåga.

Vid byggandet av en maskininlärningsmodell är det viktigt att säkerställa att varje kategori som används i modellen har tillräckligt med observationer för att modellen ska kunna lära sig generella mönster på ett pålitligt sätt.

I detta projekt har jag valt att rensa bort bilmodeller som förekom färre än tio gånger i datamängden som motsvarar mindre än 2 % av observationer per kategori. Sådana förekommer bland annat p.g.a. fel mätning vid datainsamling.




Bild 8: Fördelning i model kolumn före data städning

5. Åldersberäkning

En ny variabel, `car_age`, skapades genom att beräkna bilens ålder som skillnaden mellan aktuellt år och bilens modellår.

6. Filtrering av irrelevanta observationer

- Bilar med extremt låga (< 30 000 SEK) eller extremt höga priser (> 650 000 SEK) togs bort för att eliminera prisoutliers.

7. Reducering av datamängd

Variabler som inte ansågs vara direkt användbara för prisprognos (`date_in_traffic`, `colour`, `brand`, `region`) togs bort från analysen.

3.2 Data undersökning

Efter städningen bestod datamängden av:

- 9 variabler**, inklusive pris, bilens ålder, körsträcka, motorstyrka samt flera kategoriska attribut.
- Inga saknade värden** i de variabler som användes för modellering.

3.3 Model val

Jag skapade 3 modeller for jämförelse:

3.3.1 Model 1

3.3.1.1 `Model_initial`

skapades på den intuitiva grunden där valde jag att använda 6 factors:

```
model_initial <- lm(price ~ mile + horsepower + car_age + fuel + gearbox + drive, data = train)
```

Det gav följande resultat (se Bild 9):

```
lm(formula = price ~ mile + horsepower + car_age + fuel + gearbox +  
drive, data = train)
```

Residuals:

Min	1Q	Median	3Q	Max
-247606	-22032	-5182	19073	250244

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	224899.444	10937.197	20.563	< 2e-16 ***
mile	-5.023	0.332	-15.133	< 2e-16 ***
horsepower	708.039	45.752	15.476	< 2e-16 ***
car_age	-11740.812	609.026	-19.278	< 2e-16 ***
fueldiesel	22399.382	4137.129	5.414	8.88e-08 ***
fuel	-3464.564	6784.634	-0.511	0.610
fuelmiljöbränsle/hybrid	-129.784	5210.972	-0.025	0.980
gearboxmanuell	-8825.739	4244.370	-2.079	0.038 *
drivetvåhjuldriven	-4340.499	4667.853	-0.930	0.353

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 36570 on 607 degrees of freedom
Multiple R-squared: 0.8477, Adjusted R-squared: 0.8456
F-statistic: 422.2 on 8 and 607 DF, p-value: < 2.2e-16

Bild 9. Summary på model_initial

Den initiala modellen visade god förklaringsgrad ($R^2 \approx 0,85$), men diagnostic-plottarna (Se Bild 10) avslöjade avvikelser från antaganden om linjäritet, normalfördelning och konstant varians. För att förbättra modellen rekommenderas log-transformering av priset, behandling av inflytelserika observationer och justering av variabler med hög multikollinearitet eller låg signifikans.




Bild 10: Diagnostiska grafer för Model_initial

För att säkerställa att modellen inte påverkas negativt av multikollinearitet analyserades variablernas VIF-värden (Variance Inflation Factor). Samtliga variabler visade **låga till måttliga VIF-värden**, där inget överskred kritiska tröskelvärden (t.ex. 5 eller 10).

3.3.1.2 Model_simplified

```
model_simplified <- lm(price ~ mile + horsepower + car_age + fuel_diesel + gearbox_manuell + drive_tvahjulsdriven, data = train)
```

Följande förbättringar var genomförda:

1. Binar kodning av kategorivariabler (fuel_diesel, gearbox_manuell, drive_tvahjulsdriven)
2. Borttagning av inflytelserika observationer ("Hight Leverage " punkter):
19 observationer var borttagna Baserad på Cook's distance
3. Refit model med renare data och variabler med hög relevans (baserat på Summary)

Efter datarensning och transformationer tränades en förenklad regressionsmodell. Modellen visade god prestanda och alla regressionskoefficienter var statistiskt signifikanta ($p < 0.001$). Både Adjuster R2 och RMSE blev förbättrad : Adjusted R2 gick från 0.845 till 0.893 och RMSE sänktes från 37 797 kr till 29 650 kr vilket känns som en rimlig prediktionsprecision.

```
Call:
lm(formula = price ~ mile + horsepower + car_age + fuel_diesel +
    gearbox_manuell + drive_tvahjulsdriven, data = train)

Residuals:
    Min       1Q   Median       3Q      Max
-68292 -20547  -3508   17890   94789

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.546e+05  8.547e+03  29.784 < 2e-16 ***
mile        -5.101e+00  2.759e-01 -18.485 < 2e-16 ***
horsepower    5.560e+02  3.404e+01  16.333 < 2e-16 ***
car_age     -1.136e+04  4.887e+02 -23.248 < 2e-16 ***
fuel_diesel   1.686e+04  3.150e+03  5.351 1.25e-07 ***
gearbox_manuell -1.591e+04  3.368e+03 -4.725 2.88e-06 ***
drive_tvahjulsdriven -1.170e+04  3.367e+03 -3.474 0.00055 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 28180 on 590 degrees of freedom
Multiple R-squared:  0.8941,    Adjusted R-squared:  0.893
F-statistic: 830.2 on 6 and 590 DF,  p-value: < 2.2e-16
```

Bild 11: Model_simplified summary




Bild 12: Model_simplified diagnostiska grafer

Diagnostikplottarna för modellen visade överlag ett förbättrat resultat jämfört med tidigare modeller. Q-Q-plottar indikerade att residualerna var nära normalfördelade, och Residuals vs Fitted visade inga tydliga systematiska mönster, vilket talar för att linjäritetsantagandet är uppfyllt. Dock kvarstår viss heteroskedasticitet enligt Scale-Location-plottarna. Ett fåtal observationer med högt inflytande identifierades vilket ger utrymme för vidare förbättring.

För att verifiera att regressionsresultaten inte påverkas av multikollinearitet analyserades VIF-värdena i den förenklade modellen. Samtliga värden låg mellan 1,7 och 2,3, vilket är tydligt under kritiska gränser. Detta visar att modellens variabler är **tillräckligt oberoende** av varandra, vilket stärker förtroendet för tolkningen av deras enskilda effekter på priset.

3.3.1.3 Logaritmisk transformerad modell

Log-transformering av priset genomfördes för att förbättra modellens kvalitet. (Se Bild 13)




Bild 13: Fordelning på log transformerade bilpriser

Den ursprungliga modellen visade tecken på heteroskedasticitet, avvikelser från normalfördelning samt systematiska mönster i residualerna. Genom att log-transformera priset uppfylldes regressionsantagandena bättre, extrema värden fick mindre påverkan, och residualerna blev mer jämnt fördelade. Resultatet blev en stabilare och mer tillförlitlig modell, särskilt vid höga prisnivåer.

```
model_simplified_log <- lm(log(price) ~ mile + horsepower + car_age + fuel_diesel + gearbox_manuell +  
drive_tvahjulsdriven, data = train)
```

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.63975 -0.09456 -0.00673  0.09664  0.54533

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.267e+01  4.779e-02  265.041 < 2e-16 ***
mile          -3.219e-05  1.543e-06 -20.866 < 2e-16 ***
horsepower     2.596e-03  1.903e-04  13.641 < 2e-16 ***
car_age        -7.742e-02  2.732e-03 -28.334 < 2e-16 ***
fuel_diesel    1.061e-01  1.761e-02   6.025 2.98e-09 ***
gearbox_manuell -1.525e-01  1.883e-02  -8.100 3.18e-15 ***
drive_tvahjulsdriven -1.069e-01  1.882e-02  -5.680 2.12e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1576 on 590 degrees of freedom
Multiple R-squared:  0.9174,    Adjusted R-squared:  0.9166
F-statistic: 1092 on 6 and 590 DF,  p-value: < 2.2e-16

```

Bild 14. Log-transformerad modell summary

Efter log-transformering av priset förbättrades modellens prestanda en del (Se Bild 14). Den nya modellen förklarar över 91 % av variationen i bilpriser ($R^2 = 0,917$) och ger en medelavvikelse (MAE) på cirka 22 000 SEK. Adjusted R^2 är förbättrad från 0.893 till 0.917, RMSE i sitt tur visar lite sämre resultat på 30 869 kr jämfört med 29 650 i föregående modell. Samtliga variabler var statistiskt signifikanta, och koefficienterna visar logiska effekter: till exempel minskar bilens pris med cirka 7,7 % per års ålder, medan dieslbilar i snitt är cirka 10 % dyrare. Transformeringsen minskade också problemet med heteroskedasticitet och förbättrade residualernas fördelning.

Diagnostikplottarna (Se Bild 15) för den log-transformerade modellen visar att regressionsantagandena är väl uppfyllda. I residualplottet mot de förväntade värdena är punkterna jämnt fördelade kring noll, vilket indikerar att modellen fångar det linjära sambandet korrekt. Q-Q-plottet visar att residualerna i stort följer en normalfördelning, med endast små avvikelser i svansarna. Scale-Location-plottet tyder på konstant varians i residualerna över hela spannet av förväntade värden, vilket innebär att modellen inte uppvisar någon tydlig heteroskedasticitet. I plottet för leverage och Cook's distance syns några observationer med något högre inflytande, men inga av dessa överskrider gränsen för att anses vara extremt påverkningsfulla. Sammantaget bekräftar dessa plottar att modellen är statistiskt stabil och tillförlitlig för prediktion av bilpriser.

VIF-analysen för den log-transformerade regressionsmodellen visar att samtliga prediktorer har VIF-värden i intervallet 1,73 till 2,27. Dessa värden ligger väl under den kritiska gränsen för multikollinearitet (vanligen 5 eller 10), vilket indikerar att det inte finns någon allvarlig inbördes korrelation mellan variablerna. Modellen uppvisar därmed en god statistisk stabilitet, och de enskilda koefficienterna kan tolkas som tillförlitliga och oberoende av varandra.




Bild 15: Log transformerade modells diagnostiska grafer

3.3.2 Full model testing

Jag testade att skapa och köra full model med alla variabler som fanns kvar. Då visade det sig att modellen har problem med multikollinearitet mellan variablerna `car_type` and `model`. Alltså gick jag inte vidare med den.

3.3.3 Function Regsubsets()

Eftersom kolumnen **car_type** och **model** visade multikollinearitet valde jag att excludera model kolumn from testfunktion Regsubsets()




Bild 15. Antal optimala parametrar

Enligt diagram (Se Bild 15) i den här fallet är det värt att välja från 4 till 6 variabler att använda i modellen.

Om vi vill välja 4: mile, horsepower, car_age, fuel_diesel

For 5 variables det ska vara: mile, horsepower, car_age, fuel_diesel och car_typesuv

For 6 variabler: mile, horsepower, car_age, fuel_diesel och car_typesuv and gearbox_manuell.

Jag har skapat Model_new with 4 parametrar och i summary modell visade resultat på Adjusted R2 0.878, men den här resultatet är tagen på training data set där de extrema värdena var redan eliminerade. Diagnostiska grafer visar sådan bild (Se Bild 16):




Bild 16. Diagnostiska grafer av model_new

Eftersom resultaten är inte bättre än det första modell gick jag inte vidare i undersökningen.

4 Resultat

Arbetet inleddes med en grundmodell, `model_initial`, där alla relevanta variabler inkluderades i en multipel linjär regression. Denna modell visade redan från början god förklaringsgrad ($\text{Adjusted } R^2 \approx 0,85$) och statistiskt signifikanta prediktorer som körsträcka, hästkrafter, bilens ålder, växellåda och bränsletillhörighet. Dock identifierades vissa svagheter vid residualanalys – bland annat heteroskedasticitet, mönster i residualplottar och mindre avvikelser från normalfördelning.

För att förbättra modellen genomfördes en förenkling till `model_simplified`, där endast de mest betydelsefulla prediktorerna behölls, och kategorivariabler kodades binärt (t.ex. `fuel_diesel`, `gearbox_manuell`). Denna förenklade modell ökade $\text{Adjusted } R^2$ till 0,89 och minskade residualspridningen, samtidigt som alla prediktorer behöll signifikans. RMSE visade resultat på 29 650 kr. Även diagnostikplottarna förbättrades, men vissa mönster och en svag ökning i residualspridning vid höga priser kvarstod.

Slutligen tillämpades en log-transformering av beroende variabeln ($\log(\text{price})$), vilket resulterade i modellen `model_simplified_log`. Denna modell gav det bästa resultatet med en förklaringsgrad på 91,7 % ($\text{Adjusted } R^2 = 0,9166$) och betydligt bättre uppfyllelse av regressionsantagandena. Residualerna blev mer normalfördelade och visade ingen tydlig heteroskedasticitet. Modellens fel förbättrades inte och visade RMSE på cirka 30 869 kr.

Om vi sammanfattar var `model_simplified` och `model_simplified_log` de bäst presterade modeller. `Model_full` fungerade inte p.g.a. multikollinearitet. Och modell som formades med `Regsubsets()` funktion var utformad likadant som den ursprungliga modellen och presterade inte bättre än den ursprungliga modellen.

5 Slutsatser

Sammanfattningsvis var det modellerna `model_simplified` och `model_simplified_log` som presterade bäst. Den fullständiga modellen (`model_initial`) visade god förklaringsgrad, men påverkades negativt av viss multikollinearitet och uppfyllde inte fullt ut regressionsantagandena. En modell framtagen med `regsubsets()`-funktionen resulterade i en variabelsammansättning som i stort sett motsvarade den ursprungliga modellen, utan att ge någon förbättring i modellens prediktiva förmåga. Den log-transformerade modellen visade däremot överlägsen prestanda och uppfyllde samtliga statistiska krav på ett tillfredsställande sätt.

När det slutliga modellen, baserad på multipel linjär regression med log-transformerat pris, testades på en separat testmängd som inte använts under träning eller validering. Resultatet visade att modellen förklarade 82,25 % av variationen i bilpriserna ($R^2 = 0,8225$) och hade ett genomsnittligt prediktionsfel (RMSE) på cirka 37 359 SEK. Detta bekräftar att modellen har god generaliseringsförmåga och fungerar väl även på ny, osedd data.

Prestandan på testdatan är något lägre än på valideringsdatan (vilket är förväntat) och det finns utrymme för vidare förbättring, men modellen är praktiskt användbar redan nu.

6 Självutvärdering

6.1 Utmaningar du haft under arbetet samt hur du hanterat dem.

Den största utmaningen för mig var att knyta ihop alla tre koncept på R kursen: R språket, maschin learning och statistiken.

Att bestämma vilken data skulle behållas och vilket skulle tas bort vid Data cleaning och Data Analys var också väldigt utmanande eftersom dessa val har en direkt och betydande påverkan på modellens egenskaper och prestanda.

Mindre utmaningar var att jobba i helt ny R-studio miljö och att fatta att några R bibliotek (som t.ex. dplyr och MASS) inte alltid fungerar problemfritt tillsammans.

6.2 Vilket betyg du anser att du skall ha och varför.

Om man tar hänsyn till alla krav som ställdes tycker jag att VG kriterierna är uppfyllda av mig i hög grad. Tyvärr tog det mer tid än jag trodde alltså det är fortfarande utrymme att förbättras i time management. Samma gäller rapportskrivande. Alltså en stark G som borde gälla. Men jag är glad att jag tog denna uppgiften på högre nivå annars skulle man missa mycket i sitt lärande. Såsom Data cleaning, data transformation och Api data hantering.

Källförteckning

1. Gareth James • Daniela Witten, *An Introduction to Statistical Learning with Applications in R*, Second edition, Springer 2024
2. Chester Ismay, Albert Y. Kim, *Statistical Inference via Data Science*, second edition, CRC press 2025