

Teoretiska frågor

1. Kolla på följande video: https://www.youtube.com/watch?v=X9_ISJ0YpGw&t=290s , beskriv kortfattat vad en Quantile-Quantile (QQ) plot är.

Svar: En **Quantile-Quantile (QQ) plot** är ett grafiskt verktyg som används för att jämföra kvantilerna från en uppsättning observationer med kvantilerna från en teoretisk fördelning, vanligtvis en **normalfördelning**.

Om en uppsättning observationer är ungefär normalfördelade, kommer ett **normal-QQ-diagram** (dvs. ett QQ-plot mot den normala fördelningen) att resultera i en **ungefär rak linje**. Det är just detta vi försöker undersöka: om våra data ser ut som om de kommer från en normalfördelning.

I ett QQ-diagram ritas det **i:te ordnade värdet** (även kallat ordningsstatistik) mot den **i/(n+1):te kvantilen** av standardnormalfördelningen. På så sätt försöker vi skapa en metod som visar hur det skulle se ut om vi faktiskt hade sampel från en normalfördelning.

Att undersöka **normalitet** är viktigt, eftersom många statistiska inferensmetoder antar att vi drar stickprov från en **normalfördelad population**.

Vi kallar ibland ett quantile-quantile-diagram för ett **QQ-diagram** som en förkortning.

2.

Din kollega Karin frågar dig följande: "Jag har hört att i maskininlärning så är fokus på prediktioner medan man i statistisk regressionsanalys kan göra såväl prediktioner som statistisk inferens. Vad menas med det, kan du ge några exempel?" Vad svarar du Karin?

Svar: Jag svarar Karin att hon hört helt rätt. När man sysslar med ML fokuserar man främst på att göra så bra prediktioner som möjligt, även om man kan inte alltid förklara vad beslutet är baserat på (teoretically) . Medan vid statistisk regressionsanalys handlar det både om prediktion och statistisk analys. Alltså vi är intresserade också att se vilka prediktorer som har betydelse för utfallet.

3.

Vad är skillnaden på "konfidensintervall" och "prediktionsintervall" för predikterade värden?

Svar: Konfidensintervall baseras på ett snitt medan Prediktionsintervall uppskattar osäkerheten i en enskild prediktion och innebär därför även en större osäkerhet. Prediktionsintervall uppskattar både osäkerheten i prediktionen. Osäkerheten representeras av residualen vilken läggs in i ekvationen som Epsilon.. Prediktionsintervallen blir också bredare än konfidensintervallen pga osäkerheten.

4.

Den multipla linjära regressionsmodellen kan skrivas som: $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \epsilon$. Hur tolkas beta parametrarna?

Svar: I den multipla linjära regressionsmodellen β_0 är Interceptet, alltså den punkt där linjen skär y-axeln, medan $\beta_1, \dots, \beta_p$ är koefficienterna som bestämmer lutningen på den rätta linje som modellen beskriver. Tillsammans utgör β_0 och $\beta_1, \dots, \beta_p$ modellens koefficienter eller parametrar. ϵ (epsilon) är modellens residualen, som beskriver modellens slumpmässigt fel, det vill säga skillnaden mellan de observerade värdena och de värden som modellen predikterar.

5.

Din kollega Nils frågar dig följande: "Stämmer det att man i statistisk regressionsmodellering inte behöver använda träning, validering och test set om man nyttjar mått såsom BIC? Vad är logiken bakom detta?" Vad svarar du Hassan?

Svar: Du är rätt, Nils. Det stämmer att om man använder mått som BIC i statistisk regressionsmodellering behöver man oftast inte dela upp datan i tränings-, validerings- och testset på samma sätt som man gör i maskininlärning. BIC är konstruerat för att både mäta hur bra modellen passar datan (hur låg RSS den har) och samtidigt ta hänsyn till hur många parametrar modellen använder. Genom att lägga på en straff term för varje extra parameter, försöker BIC uppskatta hur väl modellen kommer att prestera på nya, osedda data utan att behöva hålla undan en separat del av datan för testning. Men när modellerna är mer komplicerade skulle det vara bra att använda cross validation för att dubbelkolla resultatet.

6.

Förklara algoritmen nedan för "Best subset selection"

Algorithm 6.1 *Best subset selection*

1. Let $\mathcal{M}_0$ denote the *null model*, which contains no predictors. This model simply predicts the sample mean for each observation.
 2. For $k = 1, 2, \dots, p$:
 - (a) Fit all $\binom{p}{k}$ models that contain exactly k predictors.
 - (b) Pick the best among these $\binom{p}{k}$ models, and call it $\mathcal{M}_k$. Here *best* is defined as having the smallest RSS, or equivalently largest R^2 .
 3. Select a single best model from among $\mathcal{M}_0, \dots, \mathcal{M}_p$ using using the prediction error on a validation set, C_p (AIC), BIC, or adjusted R^2 . Or use the cross-validation method.
-

Vi kan ta som example en förenklade data set på Volkswagen bilar där vi vill förutsäga **priset på en bil**, och du har **4 möjliga prediktorer**: **Mile** (antal körda mil), **Horsepower** (hästkrafter), **Car type** (biltyp, t.ex. SUV, Sedan), **Car age** (bilens ålder)

Då har vi totalt $2^4 = 16$ möjliga modeller:

1. En modell utan några prediktorer (nollmodellen)
 2. Fyra modeller med en prediktor var (mile, horsepower, car type, car age)
 3. Sex modeller med två prediktorer (t.ex. mile + horsepower, horsepower + car type, etc.)
 4. Fyra modeller med tre prediktorer (t.ex. mile + horsepower + car type)
 5. En modell med alla fyra prediktorer
-

Best Subset Selection innebär att vi:

1. Testar **alla möjliga kombinationer** av prediktorer.
2. För varje antal prediktorer, **väljer vi den modell som passar bäst** på träningsdatan med högst Adjusted R^2
3. Sedan **väljer vi slutligen den bästa modellen** bland alla dessa "vinnare", med hjälp av ett mått som straffar för överanpassning, t.ex. Cp, BIC, AIC eller genom cross validation.

7.

Ett citat från statistikern George Box är: "All models are wrong, some are useful." Förklara vad som menas med det citatet.

Med detta citat menas att alla modeller alltid predikterar med viss felmarginal, men om man tar hänsyn till detta fel kan modellen ändå förstå sambanden eller fånga det generella mönstret ganska bra och möjliggöra prediktioner. Det finns ingen idealisk modell, men man kan skapa en tillräckligt bra modell som är användbar.